

Michał Muzykant Filip Twardawa Adam Wowra		2024/2025	PSI	2
AUTOR		ROK AKAD.	SPEC.	GRUPA
ZASTOSOWANIE SIECI NEURONOWYCH I UCZENIA GŁĘBOKIEGO				3
		TEMAT	NR SPRAWOZDANIA	
16.01.2025	Zastosowanie sztucznej inteligencji		dr inż. Anna Czaderna-Lekka	
DATA WYKONANIA	PRZEDMIOT		PROWADZĄCY	

## Cel:

Celem naszego projektu jest zbudowanie efektywnych modeli głębokiego uczenia, które będą w stanie klasyfikować obrazy z zestawu danych "CIFAR-10".

## Materialy:

Zestaw danych **CIFAR-10** to powszechnie używany zbiór danych do zadań klasyfikacji obrazów. Zawiera on **60 000 obrazów** w rozdzielczości **32x32 piksele**, z czego **50 000 obrazów** służy do treningu modeli, a **10 000 obrazów** do testowania ich skuteczności. Wszystkie obrazy są trójkanałowe (RGB) i podzielone na **10 klas** reprezentujących różne kategorie obiektów.

### Opis 10 klas w zestawie danych:

1. **Airplane** (Samolot) – obrazy przedstawiające różne typy samolotów.
2. **Automobile** (Samochód) – obrazy przedstawiające samochody osobowe.
3. **Bird** (Ptak) – obrazy przedstawiające różne gatunki ptaków.
4. **Cat** (Kot) – obrazy przedstawiające różne rasy kotów.
5. **Deer** (Jeleń) – obrazy przedstawiające jelenie w ich naturalnym środowisku.
6. **Dog** (Pies) – obrazy przedstawiające różne rasy psów.
7. **Frog** (Żaba) – obrazy przedstawiające żaby w różnych sceneriach.
8. **Horse** (Koń) – obrazy przedstawiające konie, zarówno w ruchu, jak i w stanie spoczynku.
9. **Ship** (Statek) – obrazy przedstawiające statki różnych typów, takie jak jachty, łodzie czy promy.
10. **Truck** (Ciężarówka) – obrazy przedstawiające pojazdy ciężarowe.

## Metody:

### Model bazowy (Base CNN Model)

Jest to podstawowy model oparty na **konwolucyjnych sieciach neuronowych (CNN)**.

Zawiera kilka warstw konwolucyjnych i poolingowych, co pozwala na wyodrębnienie kluczowych cech obrazów. Model ten charakteryzuje się stosunkowo prostą architekturą, co umożliwia szybkie trenowanie i uzyskanie początkowych wyników. Ze względu na ograniczoną liczbę warstw model może mieć trudności z uchwyceniem bardziej złożonych wzorców w danych.

### Model pośredni (Intermediate CNN Model)

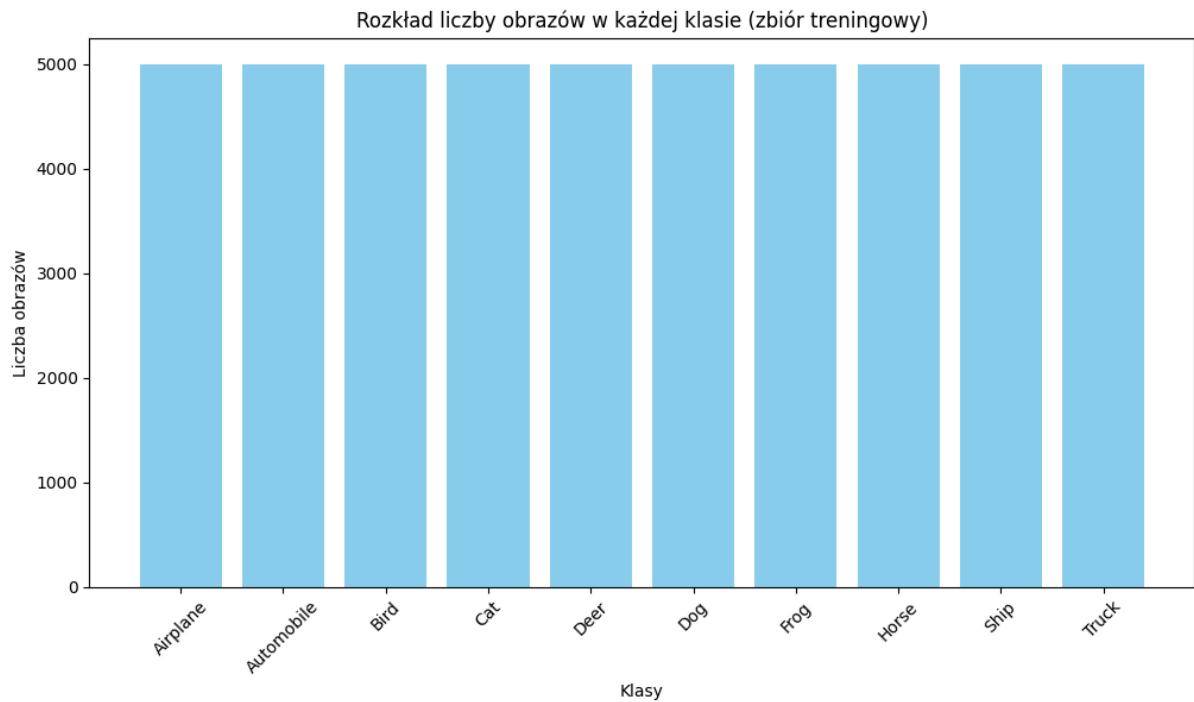
Drugi model jest rozszerzeniem modelu bazowego.

Zawiera więcej warstw konwolucyjnych i większą liczbę neuronów w warstwie gęstej, co pozwala na dokładniejsze wyodrębnienie cech obrazu i poprawę dokładności klasyfikacji.

### Model zoptymalizowany (Optimized CNN Model)

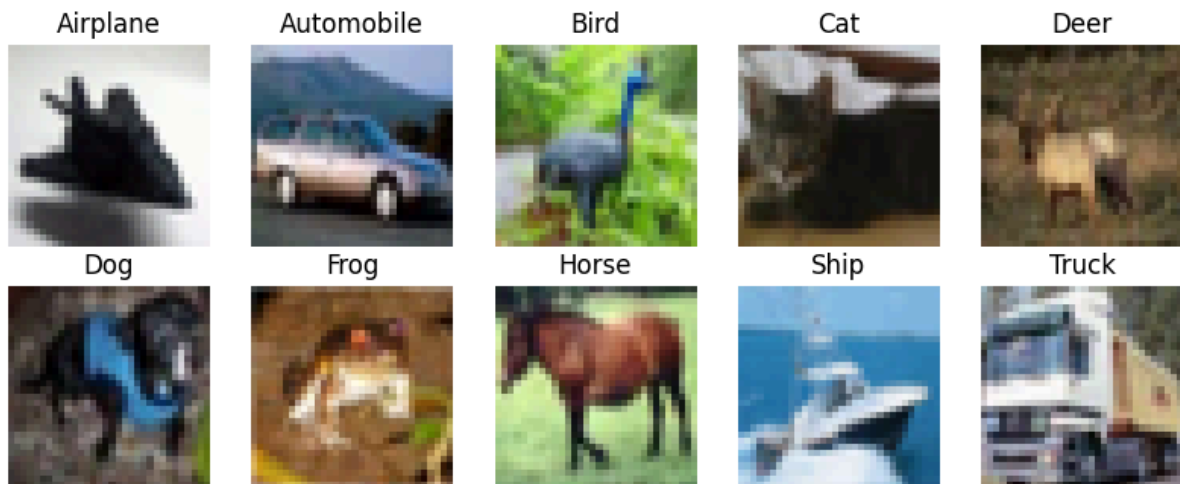
Najbardziej zaawansowany model w projekcie, który wykorzystuje techniki takie jak **normalizacja batchów (Batch Normalization)** oraz **dropout**, co pozwala na poprawę generalizacji i redukcję przetrenowania. Model zoptymalizowany został również pod kątem liczby warstw, liczby neuronów oraz funkcji aktywacji. Dzięki temu osiąga wysoką wydajność w klasyfikacji obrazów.

## Wyniki i dyskusja:



Wykres przedstawia równy rozkład liczby obrazów w każdej z 10 klas zbioru danych CIFAR-10. Każda klasa zawiera około 5 000 obrazów, co oznacza, że dane są dobrze zbalansowane.

### Przykładowe obrazy z zestawu danych CIFAR-10




Obraz przedstawia przykładowe zdjęcia każdej z 10 klas w zbiorze danych CIFAR-10. Obrazy są w niskiej rozdzielczości (32x32 piksele) i przedstawiają różnorodne obiekty, przez co dobrze nadają się do trenowania modeli klasyfikujących obiekty o różnych kolorach i kształtach.

# Przykładowe obrazy z każdej klasy (po 5 obrazów)



Obraz pokazuje różnorodność obiektów w każdej kategorii, co pozwala modelom uczyć się szerokiego zakresu cech wizualnych.




Wykres przedstawia porównanie dokładności walidacyjnej dla trzech modeli: bazowego, pośredniego i zoptymalizowanego:

**Model pośredni** (zielona linia) osiąga nieco niższe wartości w porównaniu do modelu podstawowego.

**Model bazowy** (niebieska linia) i model pośredni zachowują się w podobny sposób i osiągają stabilizację jeszcze przed 10 epoką.

**Model zoptymalizowany** (czerwona linia) osiąga najwyższą dokładność ale stabilizuje się po 10 epoce z dużymi wahaniami w okolicach 5 epoki.

Modele szybko się uczą i już przy 10 epoce dokładność modeli ulega stabilizacji.



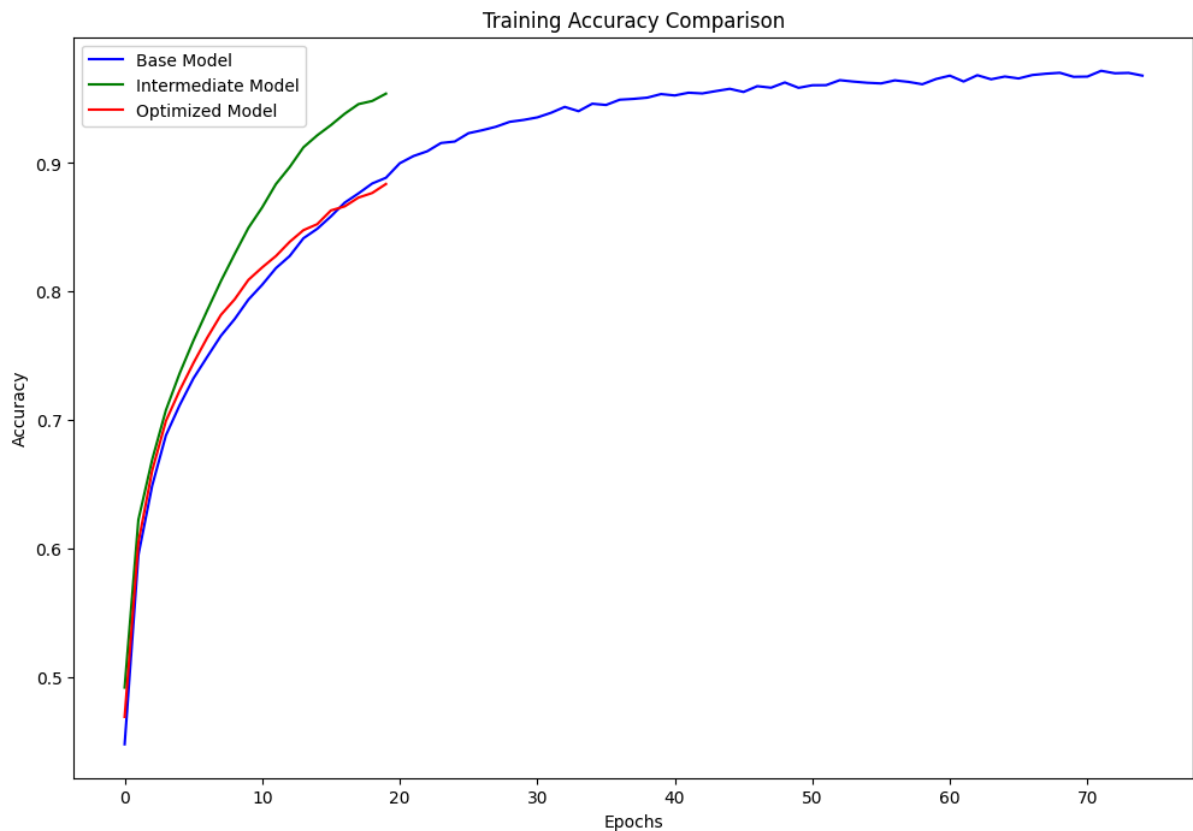
Wykres przedstawia porównanie strat walidacyjnych dla trzech modeli:

**Zoptymalizowany model** (czerwona linia) osiąga najniższe straty na początku treningu.

**Model pośredni** (zielona linia) po 10 epoce można zaobserwować nagły wzrost strat.

**Model bazowy** (niebieska linia) wykazuje ciągły wzrost strat po 10 epoce, co podobnie jak przy modelu pośrednim może sugerować przetrenowanie.

Bardziej złożone modele radzą sobie lepiej z danymi testowymi.

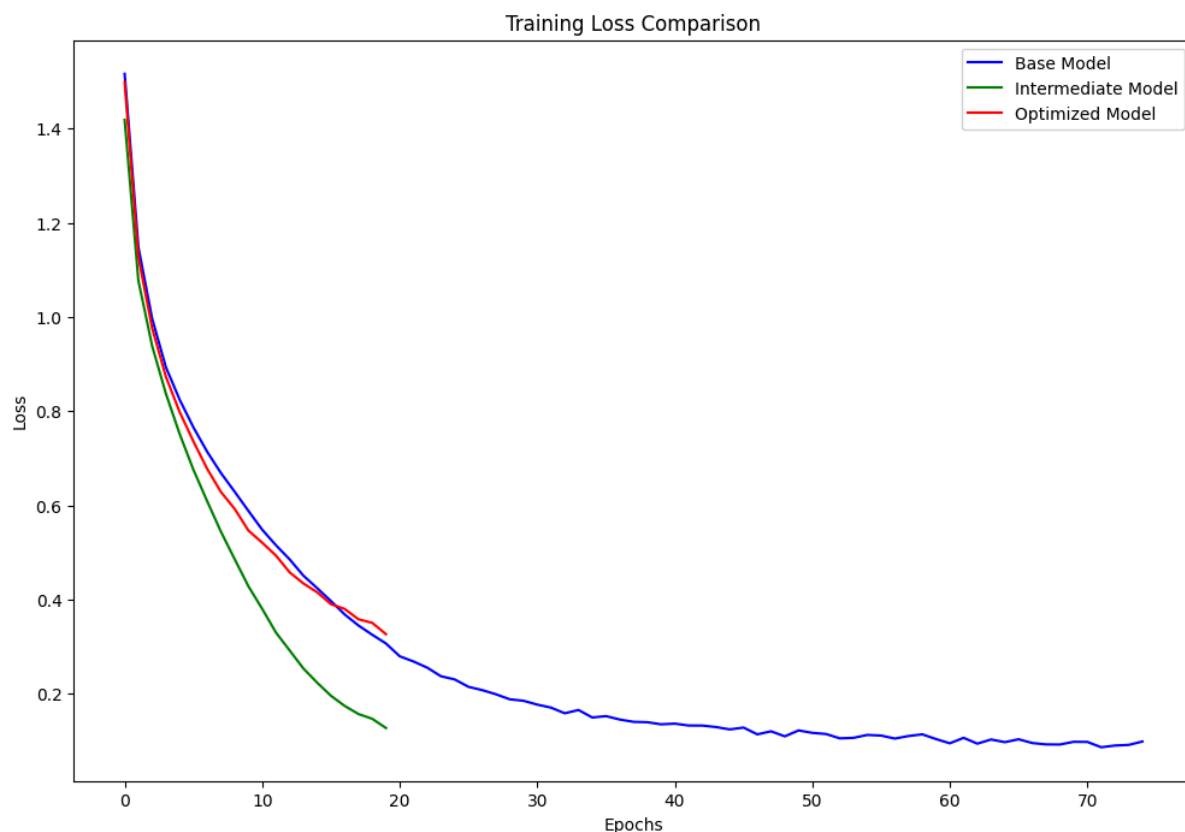


Wykres ukazuje porównanie dokładności treningowej dla trzech modeli.

**Model pośredni** (zielona linia) osiąga najwyższą dokładność, najszybciej ucząc się wzorców ze zbioru treningowego.

**Model zoptymalizowany** (czerwona linia) i **model podstawowy** (niebieska linia) uczą się w podobnym tempie.






Wykres przedstawia porównanie strat treningowych dla trzech modeli.


**Model zoptymalizowany** (czerwona linia) i **model podstawowy** (niebieska linia) w podobnym tempie przy okolicach 20 epoki stabilizują wartość strat w stosunku do danych treningowych.

**Model pośredni** (zielona linia) stabilizuje wartość strat również w okolicach 20 epoki ale spadek strat jest szybszy w porównaniu do pozostałych modeli.




Macierz błędów dla modelu podstawowego pokazuje, jak często model prawidłowo klasyfikuje obrazy oraz gdzie popełnia błędy.

Model bardzo dobrze rozpoznaje klasę **Automobile** (1) i **Truck** (9) rzadko myląc te klasy w przeciwieństwie do kategorii zwierząt takich jak **Bird** (2) i **Deer** (4).



Macierz błędów dla modelu pośredniego pokazuje lepsze wyniki w porównaniu do modelu podstawowego. Model radzi sobie lepiej z klasami Airplane (0) i Ship (8), ale nadal ma trudności z rozróżnieniem klas Bird (2) i Deer (4) oraz innych zwierząt.



Macierz błędów dla modelu zoptymalizowanego pokazuje najlepsze wyniki spośród wszystkich modeli. Większość błędów została zredukowana. Algorytm szczególnie dobrze radzi sobie z rozpoznawaniem klas Automobile (1) i Ship (8), jednak nadal występują drobne trudności z odróżnianiem klas Bird (2) i Deer (4).

## Podsumowanie:

W projekcie porównano trzy modele: bazowy, pośredni i zoptymalizowany.

- Model zoptymalizowany osiągnął najwyższą dokładność, ale jego wyniki były niestabilne w początkowych epokach.
- Model pośredni charakteryzował się stabilnym wzrostem dokładności
- Model bazowy również charakteryzował się stabilnym wzrostem dokładności, ale najgorzej dokonywał predykcji klas.

Pod względem strat walidacyjnych, model zoptymalizowany szybko osiągnął niskie wartości, natomiast model bazowy wykazał ciągły wzrost strat, co sugeruje przetrenowanie. Wszystkie modele ustabilizowały straty w okolicach 20 epoki, przy czym model pośredni osiągał je najszybciej.

Macierze błędów pokazują, że modele dobrze rozpoznają klasy Automobile i Truck, ale mają trudności z podobnymi klasami zwierząt, jak Bird i Deer. Model zoptymalizowany wykazał najlepsze wyniki, co potwierdza skuteczność zastosowanych technik, takich jak Batch Normalization i Dropout.

## **Bibliografia**

Krizhevsky, A., Hinton, G. (2009). CIFAR-10 Dataset.

Chollet, F. (2018). Deep Learning with Python.

Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep Learning.

Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift (2015).